

Prediksi Perubahan Rezim Pasar dengan Machine
Learning:
Pendekatan Komputasional untuk Mendeteksi Bullish
dan Bearish Market

[Nama Penulis]

4 Februari 2026

Daftar Isi

Prakata	11
Pengantar	13
I Fondasi Pasar dan Rezim	15
1 Memahami Rezim Pasar	17
1.1 Konsep Rezim Pasar	17
1.1.1 Definisi Rezim Pasar	17
1.1.2 Bull Market vs Bear Market	17
1.1.3 Sideways/Range-bound Market	18
1.1.4 Volatility Regimes	18
1.1.5 Market Cycles dan Fase	18
1.2 Pentingnya Identifikasi Rezim	19
1.2.1 Asset Allocation Strategy yang Dinamis	19
1.2.2 Risk Management Adaptif	19
1.2.3 Trading Strategy Selection	19
1.3 Sejarah Market Regimes: Studi Kasus	19
1.3.1 Great Depression (1929-1939)	19
1.3.2 Dot-com Bubble (1995-2002)	20
1.3.3 Financial Crisis 2008	20
1.3.4 COVID-19 Market Crash (2020)	20
2 Teori Pasar Keuangan	21
2.1 Efficient Market Hypothesis (EMH)	21
2.1.1 Tiga Bentuk Efisiensi	21
2.1.2 Kritik dan Adaptive Market Hypothesis	21
2.2 Behavioral Finance	22
2.2.1 Market Psychology: Fear and Greed	22
2.2.2 Bias Kognitif dalam Trading	22
2.3 Market Microstructure	23
2.3.1 Likuiditas dan Order Book	23
2.3.2 Peran High-Frequency Trading (HFT)	23
2.4 Analisis Teknikal sebagai Fitur ML	23
3 Pengantar Machine Learning untuk Finance	25
3.1 Mengapa Machine Learning untuk Pasar?	25
3.1.1 Kompleksitas Data Finansial	25
3.1.2 Alternative Data Integration	25

3.2	Paradigma Machine Learning dalam Konteks Trading	26
3.2.1	Supervised Learning: Prediksi Arah	26
3.2.2	Unsupervised Learning: Penemuan Pola	26
3.2.3	Reinforcement Learning: Optimalisasi Tindakan	26
3.3	Tantangan Unik ML di Finance	26
3.3.1	Low Signal-to-Noise Ratio	26
3.3.2	Non-stationarity dan Concept Drift	27
3.3.3	Backtest Overfitting	27
3.4	Validasi Model yang Benar	27
3.4.1	Bahaya Acak (Random K-Fold)	27
3.4.2	Walk-Forward Analysis	27
3.4.3	Purged K-Fold Cross Validation	27

II Data dan Feature Engineering 29

4 Sumber Data Pasar 31

4.1	Price Data (Market Data)	31
4.1.1	OHLCV: Standar Industri	31
4.1.2	Tick Data	31
4.2	Fundamental Data	31
4.2.1	Economic Indicators	31
4.2.2	Earnings Reports	32
4.2.3	Balance Sheet Metrics	32
4.2.4	Macroeconomic Data	32
4.3	Alternative Data	32
4.3.1	Sentiment dari News dan Social Media	32
4.3.2	Web Scraping	32
4.3.3	Satellite Imagery	32
4.3.4	Credit Card Transaction	32
4.3.5	Google Trends	32
4.4	Market Microstructure Data	32
4.4.1	Order Book Data (L2/L3)	32
4.4.2	Trade Flow	33
4.4.3	Price Discovery	33
4.4.4	High-Frequency Trading (HFT)	33

5 Data Preprocessing 35

5.1	Data Cleaning	35
5.1.1	Missing Data Handling	35
5.1.2	Outlier Detection	35
5.1.3	Corporate Actions Adjustment	35
5.1.4	Data Quality Checks	35
5.2	Normalization dan Transformation	35
5.2.1	Returns vs Prices	35
5.2.2	Log Returns	36
5.2.3	Standardization	36
5.2.4	Handling Non-stationarity	36
5.3	Resampling	36

5.3.1	Time-based Resampling	36
5.3.2	Tick Bars	36
5.3.3	Volume Bars	36
5.3.4	Dollar Bars	36
5.4	Train-Test Split untuk Time Series	37
5.4.1	Temporal Split	37
5.4.2	Purging dan Embargo	37
5.4.3	Cross-Validation Strategies	37
6	Technical Indicators sebagai Features	39
6.1	Trend Indicators	39
6.1.1	Moving Averages (SMA, EMA)	39
6.1.2	MACD (Moving Average Convergence Divergence)	39
6.1.3	ADX (Average Directional Index)	39
6.1.4	Parabolic SAR	39
6.2	Momentum Indicators	39
6.2.1	RSI (Relative Strength Index)	39
6.2.2	Stochastic Oscillator	40
6.2.3	Rate of Change (ROC)	40
6.2.4	Williams %R	40
6.3	Volatility Indicators	40
6.3.1	Bollinger Bands	40
6.3.2	ATR (Average True Range)	40
6.3.3	Standard Deviation	40
6.3.4	Keltner Channels	40
6.4	Volume Indicators	40
6.4.1	On-Balance Volume (OBV)	40
6.4.2	Volume Price Trend	40
6.4.3	Accumulation/Distribution	41
6.4.4	Money Flow Index	41
6.5	Custom Indicators	41
6.5.1	Kombinasi Indicators	41
6.5.2	Adaptive Indicators	41
6.5.3	Multi-timeframe Features	41
7	Advanced Feature Engineering	43
7.1	Statistical Features	43
7.1.1	Rolling Statistics (Mean, Variance)	43
7.1.2	Higher Moments (Skewness Kurtosis)	43
7.1.3	Autocorrelation dan Serial Correlation	43
7.1.4	Fractal Dimension (Hurst Exponent)	44
7.2	Microstructure Features	44
7.2.1	Bid-Ask Spread dynamics	44
7.2.2	Order Imbalance	44
7.2.3	Kyle's Lambda (Amihud Illiquidity)	44
7.3	Feature Selection Techniques	44
7.3.1	Correlation Clustering	44
7.3.2	Feature Importance (MDI)	45

III	Metodologi dan Algoritma	47
8	Regime Labeling	49
8.1	Metode Labeling Manual vs Data-Driven	49
8.1.1	Price-based Rules (Naive)	49
8.1.2	Drawdown-based Labeling	49
8.2	Statistical Change Point Detection	49
8.3	Hidden Markov Models (HMM)	49
8.3.1	Konsep Latent States	49
8.3.2	Matriks Transisi	49
8.3.3	Gaussian Mixture Emissions	50
8.4	Regime-Switching Models Lainnya	50
9	Classification Models untuk Regime Prediction	51
9.1	Traditional Machine Learning	51
9.1.1	Logistic Regression	51
9.1.2	Random Forest	51
9.1.3	Gradient Boosting (XGBoost, LightGBM)	51
9.1.4	Support Vector Machines (SVM)	51
9.2	Handling Imbalanced Data	51
10	Deep Learning untuk Regime Detection	53
10.1	Feedforward Neural Networks (MLP)	53
10.2	Convolutional Neural Networks (CNN)	53
10.3	Recurrent Neural Networks (RNN)	53
10.3.1	LSTM (Long Short-Term Memory)	53
10.3.2	Attention Mechanisms dan Transformers	53
11	Time Series Models	55
11.1	Classical Time Series	55
11.1.1	ARIMA	55
11.1.2	GARCH untuk Volatility	55
11.1.3	VAR (Vector Autoregression)	55
11.2	Modern Time Series ML	55
11.2.1	Prophet	55
11.2.2	N-BEATS	55
12	Unsupervised Learning untuk Regime Discovery	57
12.1	Clustering Methods	57
12.1.1	K-Means	57
12.1.2	GMM (Gaussian Mixture Models)	57
12.2	Dimensionality Reduction	57
12.2.1	PCA	57
12.2.2	Autoencoders	57
13	Reinforcement Learning	59
13.1	Konsep RL untuk Trading	59
13.2	RL Algorithms	59
13.2.1	Deep Q-Networks (DQN)	59

13.2.2 PPO (Proximal Policy Optimization)	59
13.3 RL untuk Regime-aware Trading	59
IV Evaluasi dan Optimisasi	61
14 Evaluasi Model	63
14.1 Classification Metrics	63
14.1.1 Precision, Recall, F1	63
14.1.2 Confusion Matrix	63
14.2 Financial Metrics	63
14.2.1 Sharpe Ratio Sortino Ratio	63
14.2.2 Maximum Drawdown	63
14.3 Backtesting yang Benar	63
14.3.1 Walk-Forward Validation	63
14.3.2 Purged Cross-Validation	63
15 Model Optimization	65
15.1 Hyperparameter Tuning	65
15.1.1 Grid Search vs Random Search	65
15.1.2 Bayesian Optimization (Optuna)	65
15.2 Feature Selection	65
15.2.1 Recursive Feature Elimination (RFE)	65
15.2.2 SHAP Values	65
16 Model Interpretability	67
16.1 Explainable AI (XAI)	67
16.1.1 SHAP LIME	67
16.1.2 Feature Importance Plot	67
17 Implementasi Sistem Real-time	69
17.1 Arsitektur Sistem	69
17.1.1 Data Pipeline	69
17.1.2 Model Serving	69
17.1.3 API Design	69
17.1.4 Scalability	69
17.2 Real-time Data Processing	69
17.2.1 Streaming Data	69
17.2.2 Low-latency Processing	69
17.2.3 Data Quality Monitoring	70
17.3 Model Deployment	70
17.3.1 Model Serialization	70
17.3.2 Version Control	70
17.3.3 A/B Testing	70
17.3.4 Model Monitoring	70
17.4 Infrastructure	70
17.4.1 Cloud vs On-premise	70
17.4.2 Containerization (Docker)	70
17.4.3 Orchestration (Kubernetes)	70

18 Trading Strategies berbasis Regime	71
18.1 Regime-conditional Strategies	71
18.1.1 Bull Market Strategies	71
18.1.2 Bear Market Strategies	71
18.1.3 Sideways Market Strategies	71
18.2 Portfolio Allocation	72
18.2.1 Dynamic Asset Allocation	72
18.2.2 Risk Parity	72
18.2.3 Tactical Allocation	72
18.3 Risk Management	72
18.3.1 Position Sizing	72
18.3.2 Stop Loss Strategies	72
18.3.3 Hedging	72
18.3.4 Diversification	72
18.4 Execution	72
18.4.1 Order Types	72
18.4.2 Execution Algorithms	73
18.4.3 Market vs Limit Orders	73
19 Studi Kasus: Saham	75
19.1 Data Preparation	75
19.2 Feature Engineering	75
19.3 Model Development	75
19.4 Backtesting Results	75
19.5 Live Trading Performance	75
19.6 Lessons Learned	75
20 Studi Kasus: Cryptocurrency	77
20.1 Karakteristik Crypto Markets	77
20.2 Data Sources	77
20.3 Model Adaptation	77
20.4 Results dan Analysis	77
21 Studi Kasus: Forex	79
21.1 Currency Pair Selection	79
21.2 Multi-timeframe Analysis	79
21.3 Macro Factors	79
21.4 Implementation	79
22 Studi Kasus: Multi-asset	81
22.1 Cross-asset Correlations	81
22.2 Global Regime Detection	81
22.3 Portfolio Construction	81
22.4 Performance Evaluation	81
V Topics Lanjutan	83
23 Online Learning dan Adaptive Models	85

23.1	Concept Drift	85
23.1.1	Deteksi Drift	85
23.1.2	Adaptation Strategies	85
23.2	Online Learning Algorithms	85
23.2.1	Incremental Learning	85
23.2.2	Transfer Learning	85
23.2.3	Meta-learning	85
23.3	Model Updating	86
23.3.1	Retraining Frequency	86
23.3.2	Sliding Window	86
23.3.3	Weighted Recent Data	86
24	Alternative Approaches	87
24.1	Bayesian Methods	87
24.1.1	Bayesian Networks	87
24.1.2	Gaussian Processes	87
24.1.3	Bayesian Optimization	87
24.2	Fuzzy Logic	87
24.2.1	Fuzzy Sets	87
24.2.2	Fuzzy Rules	87
24.2.3	Fuzzy Inference Systems	87
24.3	Genetic Algorithms	88
24.3.1	Evolution Strategies	88
24.3.2	Strategy Optimization	88
24.4	Graph Neural Networks (GNN)	88
24.4.1	Market Networks	88
24.4.2	Correlation Graphs	88
25	Explainability dan Transparency	89
25.1	Black Box vs White Box Models	89
25.2	Regulatory Requirements	89
25.3	Stakeholder Communication	89
25.4	Trust dan Validation	89
26	Trends dan Inovasi	91
26.1	Quantum Machine Learning	91
26.2	Federated Learning	91
26.3	Neuromorphic Computing	91
26.4	Alternative Data Explosion	91
27	Challenges dan Limitations	93
27.1	Market Regime Changes	93
27.2	Black Swan Events	93
27.3	Data Quality Issues	93
27.4	Computational Limits	93
27.5	Ethical Considerations	93
28	Kesimpulan	95
28.1	Rangkuman	95

28.2	Best Practices	95
28.3	Practical Recommendations	95
28.4	Final Thoughts	95
A	Kode dan Implementasi	97
A.1	Setup Environment	97
A.1.1	Python Libraries	97
A.1.2	R Packages	97
A.1.3	Trading Platforms	97
A.2	Data Acquisition	97
A.2.1	API Examples	97
A.2.2	Web Scraping Code	97
A.2.3	Database Setup	97
A.3	Model Templates	97
A.3.1	Classification Template	97
A.3.2	Deep Learning Template	98
A.3.3	Backtesting Template	98
A.4	Complete Examples	98
A.4.1	End-to-end Pipeline	98
A.4.2	Production-ready Code	98
B	Glossary	99
B.1	Machine Learning Terms	99
B.2	Finance Terms	99
B.3	Statistical Terms	99
	Daftar Pustaka	101
	Indeks	103

Prakata

Pasar keuangan adalah binatang yang terus berubah. Apa yang berhasil hari ini mungkin akan gagal total besok. Bagi para pedagang dan investor, kemampuan untuk mengenali "musim" pasar—apakah kita sedang berada di tengah badai penurunan, hari cerah kenaikan, atau kabut ketidakpastian yang mendatar—adalah keterampilan yang membedakan antara mereka yang bertahan dan mereka yang tergerus oleh volatilitas.

Buku ini ditulis dari frustrasi dan harapan. Frustrasi melihat banyaknya model trading yang kaku dan gagal beradaptasi saat kondisi pasar berubah. Harapan bahwa dengan kemajuan teknologi, khususnya *Machine Learning*, kita sekarang memiliki alat untuk mendeteksi perubahan rezim ini secara lebih objektif dan cepat daripada sebelumnya.

Tujuan saya menulis buku ini bukan untuk memberikan "kotak hitam" ajaib penghasil uang, melainkan untuk memberikan kerangka kerja komputasional. Bagaimana kita bisa mengajarkan komputer untuk mengenali pola-pola halus yang menandakan pergeseran sentimen pasar? Bagaimana kita memvalidasi sinyal tersebut? Dan yang terpenting, bagaimana kita menyesuaikan strategi kita berdasarkan deteksi tersebut?

Semoga buku ini menjadi panduan bermanfaat bagi siapa saja yang ingin menavigasi kompleksitas pasar modern dengan bantuan kecerdasan buatan.

[Kota, Tanggal]
Penulis

Pengantar

Latar Belakang

Model keuangan tradisional seringkali berasumsi bahwa parameter pasar (seperti rata-rata imbal hasil dan volatilitas) adalah konstan sepanjang waktu atau mengikuti distribusi normal yang dapat diprediksi. Namun, realitas sejarah menunjukkan sebaliknya: pasar sering mengalami perubahan struktural mendadak atau "perubahan rezim". Krisis finansial 2008 dan keruntuhan pasar akibat COVID-19 pada 2020 adalah pengingat brutal bahwa strategi yang didasarkan pada data masa damai bisa hancur dalam hitungan hari saat rezim berubah.

Tujuan Buku

Buku ini bertujuan untuk:

- Menjelaskan konsep rezim pasar secara mendalam, melampaui definisi biner Bull vs Bear sederhana.
- Memperkenalkan aplikasi algoritma Machine Learning (dari HMM hingga Deep Learning) khusus untuk tugas deteksi rezim.
- Memberikan panduan praktis tentang data preprocessing dan feature engineering yang relevan untuk data finansial yang *noisy*.
- Menjembatani teori keuangan modern dengan praktik data science terapan.

Struktur Buku

Buku ini dibagi menjadi lima bagian utama:

- **Bagian I: Fondasi Pasar dan Rezim** membahas teori dasar pasar dan mengapa rezim terbentuk.
- **Bagian II: Data dan Feature Engineering** fokus pada seni mengolah data pasar menjadi sinyal yang berguna.
- **Bagian III: Metodologi dan Algoritma** mengupas berbagai model ML untuk klasifikasi rezim.
- **Bagian IV: Evaluasi dan Optimisasi** membahas cara menguji dan memperbaiki model trading.

- **Bagian V: Implementasi dan Aplikasi** memberikan contoh kode dan strategi konkret.

Kepada Siapa Buku Ini Ditujukan

- **Quantitative Traders/Researchers:** Yang ingin meningkatkan model mereka dengan overlay deteksi rezim.
- **Data Scientists:** Yang tertarik terjun ke domain finansial dan memahami tantangan unik data pasar.
- **Portfolio Managers:** Yang membutuhkan pendekatan sistematis untuk manajemen risiko dinamis.
- **Mahasiswa Keuangan/Komputer:** Yang mencari referensi interdisipliner tentang Financial Machine Learning.

Bagian I

Fondasi Pasar dan Rezim

Bab 1

Memahami Rezim Pasar

1.1 Konsep Rezim Pasar

1.1.1 Definisi Rezim Pasar

Dalam dinamika sistem kompleks seperti pasar keuangan, "rezim" merujuk pada periode stabilitas relatif dalam perilaku statistik data. Jika kita memandang pasar sebagai sistem stokastik, rezim pasar adalah keadaan (*state*) di mana parameter distribusi probabilitas yang mendasari (seperti mean μ , varians σ^2 , dan korelasi ρ) cenderung konstan atau berubah secara perlahan.

Berbeda dengan pandangan linier yang menganggap pasar bergerak dalam satu kontinum yang mulus, konsep rezim mengakui adanya perubahan struktural (*structural breaks*). Misalnya, perilaku harga saham saat krisis likuiditas global (Rezim Krisis) secara fundamental berbeda aturan mainnya dibandingkan saat ekonomi tumbuh stabil (Rezim Pertumbuhan). Korelasi antar aset yang biasanya rendah bisa tiba-tiba melonjak mendekati 1 saat kepanikan melanda, menggagalkan strategi diversifikasi tradisional. Memahami pergeseran ini adalah kunci untuk bertahan hidup di pasar.

1.1.2 Bull Market vs Bear Market

Secara tradisional, pelaku pasar membagi kondisi menjadi dua kategori biner:

- **Bull Market:** Didefinisikan secara umum sebagai periode kenaikan harga aset sebesar 20% atau lebih dari titik terendah sebelumnya. Karakteristik psikologisnya adalah optimisme, kepercayaan investor yang tinggi, dan ekspektasi pertumbuhan ekonomi yang kuat. Secara historis, Bull Market cenderung berlangsung lebih lama (rata-rata 2-5 tahun) dengan volatilitas yang relatif rendah. Data historis S&P 500 menunjukkan bahwa Bull Market membangun kekayaan secara perlahan namun konsisten.
- **Bear Market:** Didefinisikan sebagai penurunan harga aset sebesar 20% atau lebih dari puncaknya. Ini ditandai dengan pesimisme luas, ketakutan, dan kontraksi ekonomi. Bear Market cenderung lebih pendek (rata-rata 8-18 bulan) tetapi jauh lebih ganas dan volatil. Penurunan harga sering terjadi sangat cepat ("Pasar naik lewat tangga, turun lewat lift"), yang mencerminkan panik penjualan.

Namun, definisi persentase statis ini memiliki kelemahan fatal: ia bersifat *lagging*. Pada saat pasar dikonfirmasi turun 20%, investor mungkin sudah kehilangan sebagian besar

modalnya. Pendekatan Machine Learning mencoba mendeteksi probabilitas peralihan ke Bear Market jauh sebelum ambang batas 20% itu tercapai.

1.1.3 Sideways/Range-bound Market

Seringkali diabaikan dalam dikotomi Bull/Bear, rezim *Sideways* adalah kondisi di mana harga beresilasi dalam rentang horizontal yang terbatas tanpa tren arah yang jelas. Ini adalah "kuburan" bagi strategi *trend-following* yang mengandalkan momentum berkelanjutan. Sebaliknya, strategi *mean-reversion* (beli di *support*, jual di *resistance*) justru memanen profit terbesar di sini. Mengidentifikasi rezim ini sangat krusial untuk menonaktifkan algoritma yang rentan terhadap sinyal palsu (*whipsaw*).

1.1.4 Volatility Regimes

Selain arah (Directional Regime), dimensi kedua yang tak kalah penting adalah volatilitas. Kita bisa membagi pasar menjadi:

- **Low Volatility Regime:** Pergerakan harga harian kecil dan teratur. Sering terjadi pada fase pemulihan ekonomi atau Bull Market yang matang. Strategi dengan leverage tinggi (*carry trade*) sering bekerja baik di sini.
- **High Volatility Regime:** Pergerakan harga harian besar dan tak terduga. Ini biasanya terjadi saat rilis berita makroekonomi besar, krisis geopolitik, atau transisi menuju Bear Market. Risiko *gap opening* sangat tinggi, menuntut manajemen risiko yang ketat.

1.1.5 Market Cycles dan Fase

Richard Wyckoff, seorang pionir analisis teknikal awal abad ke-20, memetakan siklus pasar menjadi empat fase distrik yang relevan hingga hari ini:

1. **Akumulasi:** Periode sideways setelah penurunan panjang, di mana *smart money* (institusi) mulai membeli aset secara diam-diam dari investor ritel yang putus asa.
2. **Markup (Uptrend):** Fase kenaikan harga yang nyata, partisipasi publik mulai masuk, dan optimisme meningkat. Ini adalah fase Bull Market.
3. **Distribusi:** Periode sideways di puncak, di mana *smart money* mulai menjual kepemilikan mereka kepada investor ritel yang baru masuk karena euforia (FOMO).
4. **Markdown (Downtrend):** Fase penurunan harga saat pasokan melebihi permintaan, memicu Bear Market.

Machine Learning dapat dilatih untuk mengklasifikasikan data pasar saat ini ke dalam salah satu dari empat fase Wyckoff ini, memberikan peta jalan taktis bagi trader.

1.2 Pentingnya Identifikasi Rezim

1.2.1 Asset Allocation Strategy yang Dinamis

Model portofolio statis seperti portofolio 60/40 (60% saham, 40% obligasi) berasumsi bahwa korelasi negatif antara saham dan obligasi akan selalu melindungi investor. Namun, pada tahun 2022, baik saham maupun obligasi jatuh bersamaan karena rezim inflasi tinggi. Dengan identifikasi rezim yang akurat, manajer investasi dapat melakukan *Dynamic Asset Allocation*:

- Saat deteksi **Rezim Inflasi**: Alihkan dana ke Komoditas atau Emas.
- Saat deteksi **Rezim Resesi**: Pindah ke *Cash* atau *Government Bonds* jangka pendek.
- Saat deteksi **Rezim Pertumbuhan**: *Overweight* pada Ekuitas (Saham).

1.2.2 Risk Management Adaptif

Manajemen risiko yang kaku seringkali gagal. Stop-loss 2% mungkin terlalu sempit di pasar volatil (mudah terkena *stop-out* prematur) tetapi terlalu lebar di pasar tenang. Sistem berbasis rezim menyesuaikan parameter risiko secara otomatis:

- **Position Sizing**: Kurangi ukuran posisi setengahnya saat model mendeteksi probabilitas tinggi beralih ke rezim volatilitas tinggi.
- **Volatility-Adjusted Stop Loss**: Perlebar jarak stop-loss saat volatilitas meningkat untuk memberi ruang bernafas bagi harga (*atr-based stops*).

1.2.3 Trading Strategy Selection

Tidak ada strategi tunggal yang berhasil di semua kondisi pasar.

- **Trend Follower**: Profit besar di Bull/Bear Market, rugi besar di Sideways.
- **Mean Reversion**: Profit konsisten di Sideways, hancur lebur saat pasar trending kuat (melawan tren).

Sistem meta-learning dapat bertindak sebagai "pelatih" yang memilih pemain (strategi) mana yang diterjunkan ke lapangan berdasarkan kondisi cuaca (rezim) saat ini.

1.3 Sejarah Market Regimes: Studi Kasus

Mempelajari sejarah bukan sekadar hafalan, tetapi memahami pola berulang yang didorong oleh psikologi manusia yang tetap sama.

1.3.1 Great Depression (1929-1939)

Contoh paling ekstrem dari Bear Market sekuler. Pasar saham AS kehilangan hampir 90% nilainya. Ini mengajarkan bahwa pasar tidak selalu "kembali normal" dalam waktu singkat. Rezim deflasi yang parah mengubah korelasi aset secara drastis, di mana *Cash is King*. Perubahan regulasi pasca-depresi menciptakan rezim pasar baru yang bertahan puluhan tahun.

1.3.2 Dot-com Bubble (1995-2002)

Studi kasus klasik tentang euforia irasional. Valuasi saham teknologi terputus dari fundamental (banyak perusahaan tanpa profit dihargai miliaran dolar). Rezim ini ditandai oleh volatilitas sisi atas (*upside volatility*) yang ekstrem. Pelajaran utamanya: pasar bisa tetap irasional lebih lama daripada kemampuan Anda menahan solvabilitas (seperti kata John Maynard Keynes). Deteksi rezim berbasis valuasi akan memberi sinyal "Bubble" bertahun-tahun sebelum pecah.

1.3.3 Financial Crisis 2008

Krisis ini unik karena sifatnya yang sistemik. Produk derivatif kompleks (MBS/CDO) menyembunyikan risiko yang sebenarnya. Saat gelembung perumahan pecah, efek penularan (*contagion*) menyebar ke seluruh dunia. Rezim ini ditandai oleh krisis likuiditas: aset bagus pun dijual paksa untuk menutupi *margin call*. Korelasi antar semua kelas aset mendekati 1, menggagalkan diversifikasi. Machine Learning yang memantau *Credit Spreads* (selisih yield obligasi korporasi dan pemerintah) bisa mendeteksi tanda-tanda stres sistemik ini berbulan-bulan sebelumnya.

1.3.4 COVID-19 Market Crash (2020)

Contoh *Black Swan* sempurna. Penurunan tercepat dalam sejarah pasar (Bear Market dalam hitungan minggu), diikuti oleh pemulihan berbentuk V tercepat dalam sejarah berkat intervensi bank sentral. Ini menciptakan siklus pasar yang "dipercepat". Model yang dilatih pada data historis lambat mungkin gagal beradaptasi dengan kecepatan perubahan ini, menekankan perlunya model adaptif (*online learning*).

Bab 2

Teori Pasar Keuangan

Landasan teoritis sangat penting untuk membumikan model Machine Learning kita. Tanpa pemahaman tentang ekonomi dan perilaku pasar, seorang data scientist hanya akan menemukan korelasi palsu (*spurious correlations*) dalam data. Kita perlu memahami "mengapa" pasar bergerak (teori) sebelum memprediksi "bagaimana" ia bergerak (ML).

2.1 Efficient Market Hypothesis (EMH)

Diajukan oleh Eugene Fama pada tahun 1960-an, EMH adalah pilar keuangan modern yang menyatakan bahwa harga aset selalu mencerminkan secara penuh semua informasi yang tersedia. Menurut teori ini, tidak mungkin untuk mengalahkan pasar secara konsisten (mencetak *alpha*) karena setiap informasi baru langsung diserap ke dalam harga seketika.

2.1.1 Tiga Bentuk Efisiensi

EMH dibagi menjadi tiga tingkatan:

1. **Weak Form (Bentuk Lemah):** Harga saat ini sudah mencerminkan semua data harga dan volume masa lalu. Implikasinya: *Analisis Teknikal* (melihat grafik) tidak berguna karena pola masa lalu tidak memprediksi masa depan. Pergerakan harga adalah "Jalan Acak" (*Random Walk*).
2. **Semi-strong Form (Bentuk Semi-kuat):** Harga mencerminkan semua informasi publik (laporan keuangan, berita, data makro). Implikasinya: *Analisis Fundamental* tidak memberikan keunggulan, karena begitu berita bagus rilis, harga sudah menyesuaikan diri sebelum Anda sempat klik "Beli".
3. **Strong Form (Bentuk Kuat):** Harga mencerminkan *semua* informasi, termasuk informasi privat atau orang dalam (*insider*). Implikasinya: Bahkan CEO perusahaan atau insider trading pun tidak bisa mengalahkan pasar dalam jangka panjang.

2.1.2 Kritik dan Adaptive Market Hypothesis

Bagi praktisi ML, EMH dalam bentuk murninya adalah berita buruk—jika pasar efisien sempurna, maka tidak ada pola untuk dipelajari, dan prediksi adalah mustahil. Namun, segunung bukti empiris dan kesuksesan dana lindung nilai (*hedge funds*) kuantitatif

membantah EMH bentuk kuat. Andrew Lo mengusulkan ****Adaptive Market Hypothesis (AMH)**** sebagai sintesis. AMH menyatakan bahwa efisiensi pasar bukanlah kondisi biner (Efisien/Tidak Efisien), melainkan spektrum yang berubah-ubah tergantung kondisi lingkungan (rezim).

- Di pasar yang tenang dan matang, efisiensi tinggi (sulit diprediksi).
- Di masa panik, krisis, atau adanya pelaku pasar baru yang tidak rasional, efisiensi menurun, menciptakan inefisiensi yang bisa dieksploitasi oleh algoritma ML.

Buku ini berlandaskan pada premis AMH: kita menggunakan ML untuk mencari "kantong-kantong inefisiensi" ini.

2.2 Behavioral Finance

Jika EMH mengasumsikan pelaku pasar adalah robot rasional ("Homo Economicus"), Behavioral Finance mengakui bahwa pasar diisi oleh manusia yang emosional dan bias. Perubahan rezim seringkali lebih didorong oleh psikologi massa daripada perubahan fundamental ekonomi.

2.2.1 Market Psychology: Fear and Greed

Pasar berayun seperti pendulum antara ketakutan (fear) dan keserakahan (greed).

- **Greed (Rezim Bull):** Investor mengabaikan risiko, valuasi menjadi tidak masuk akal, dan rasa takut ketinggalan (FOMO) mendorong harga naik melampaui nilai wajarnya.
- **Fear (Rezim Bear):** Investor mengabaikan peluang, menjual aset bagus dengan harga diskon karena panik. VIX (indeks volatilitas) adalah "termometer ketakutan" yang bisa menjadi fitur input ML yang sangat kuat.

2.2.2 Bias Kognitif dalam Trading

- **Herding Behavior (Perilaku Menggembala):** Manusia merasa lebih aman mengikuti orang banyak. Jika semua orang menjual, insting kita menyuruh ikut jual. Ini menciptakan tren momentum yang panjang dan berlebihan (*overshoot*).
- **Loss Aversion:** Teori Prospek (Kahneman Tversky) menunjukkan bahwa rasa sakit akibat rugi \$100 dua kali lebih besar daripada rasa senang untung \$100. Ini menjelaskan mengapa pasar jatuh lebih cepat daripada naiknya (Panic Selling lebih intens daripada Panic Buying).
- **Confirmation Bias:** Trader cenderung hanya mencari berita yang mendukung posisi mereka dan mengabaikan sinyal bahaya. Algoritma ML yang objektif membantu memitigasi bias manusia ini.

2.3 Market Microstructure

Sementara teori makro menjelaskan tren jangka panjang, *Market Microstructure* membahas mekanika detail bagaimana perdagangan terjadi di level *tick-by-tick*. Untuk strategi frekuensi tinggi atau eksekusi algoritma, pemahaman ini vital.

2.3.1 Likuiditas dan Order Book

Pasar terdiri dari *Limit Order Book* (LOB).

- **Bid:** Harga tertinggi yang bersedia dibayar pembeli.
- **Ask/Offer:** Harga terendah yang diminta penjual. **Spread:** Selisih Ask - Bid. Spread yang melebar adalah indikator awal stres pasar atau penurunan likuiditas.

Dalam rezim krisis, likuiditas sering "menguap" tiba-tiba, memperburuk kejatuhan harga karena tidak ada pembeli yang bersedia menampung (*liquidity black hole*).

2.3.2 Peran High-Frequency Trading (HFT)

Sebagian besar volume pasar modern didominasi oleh algoritma HFT. Mereka menyediakan likuiditas tetapi juga bisa menariknya dalam milidetik (*quote stuffing/spoofing*). Pola-pola mikro yang dihasilkan HFT menciptakan "noise" yang harus dibersihkan sebelum melatih model ML untuk prediksi trend jangka panjang. Namun, jejak kaki HFT (seperti ketidakseimbangan order flow) juga bisa menjadi fitur prediktif jangka pendek.

2.4 Analisis Teknikal sebagai Fitur ML

Banyak akademisi mencemooh analisis teknikal sebagai "voodoo", tetapi bagi praktisi ML, indikator teknikal adalah metode *feature engineering* yang valid untuk menangkap psikologi pasar.

- **Support/Resistance:** Level memori pasar di mana harga pernah berbalik.
- **Moving Averages:** Filter low-pass yang meredam noise untuk menonjolkan tren sinyal.
- **RSI/Oscillators:** Ukuran kecepatan perubahan harga untuk mendeteksi kondisi jenuh (overbought/oversold).

Alih-alih menggunakan aturan kaku ("Beli jika RSI > 30"), ML menggunakan nilai-nilai ini sebagai input vektor untuk mempelajari aturan keputusan yang lebih kompleks dan nuansa secara non-linear.

Bab 3

Pengantar Machine Learning untuk Finance

Machine Learning (ML) telah mengubah lanskap industri keuangan, bergerak dari sekadar alat statistik tambahan menjadi mesin utama penggerak keputusan investasi. Namun, menerapkan ML pada data keuangan bukanlah tugas yang mudah; bidang ini penuh dengan jebakan yang tidak ditemukan dalam domain lain seperti pengenalan gambar atau pemrosesan bahasa alami.

3.1 Mengapa Machine Learning untuk Pasar?

3.1.1 Kompleksitas Data Finansial

Data pasar keuangan adalah representasi dari psikologi jutaan pelaku pasar yang berinteraksi secara real-time. Data ini bersifat *noisy*, *chaotic*, dan seringkali tidak terstruktur. Model ekonometrika tradisional (seperti regresi linier OLS) bekerja berdasarkan asumsi yang seringkali tidak realistis, seperti hubungan yang linier dan residu yang terdistribusi normal. Machine Learning, khususnya model non-parametrik seperti *Decision Trees* dan *Neural Networks*, tidak memaksakan asumsi bentuk pada data. Mereka memiliki fleksibilitas untuk mempelajari pola non-linear yang kompleks dan interaksi antar variabel yang halus (misalnya: korelasi antara Emas dan Dolar mungkin hanya kuat saat inflasi di atas 3

3.1.2 Alternative Data Integration

Revolusi terbesar ML di finance adalah kemampuannya menelan data non-tradisional. Sementara model lama terbatas pada harga dan volume, ML dapat memproses:

Text Data: Sentimen berita, tweet, dan transkrip earning calls.

- **Image Data:** Citra satelit parkir Walmart untuk memprediksi pendapatan ritel.
- **Network Data:** Hubungan rantai pasok antar perusahaan global.

Kemampuan untuk mengubah data mentah yang tidak terstruktur ini menjadi sinyal trading yang dapat ditindaklanjuti adalah keunggulan kompetitif utama (*edge*).

3.2 Paradigma Machine Learning dalam Konteks Trading

3.2.1 Supervised Learning: Prediksi Arah

Ini adalah paradigma yang paling umum digunakan. Tujuannya adalah memetakan fitur (X) ke target (Y).

- **Klasifikasi:** Memprediksi arah harga diskrit. Contoh: "Apakah harga besok akan Naik (1) atau Turun (0)?" . Aplikasi lain adalah deteksi penipuan kartu kredit.
- **Regresi:** Memprediksi nilai kontinu. Contoh: "Berapa harga penutupan S&P 500 besok?" . Perlu dicatat bahwa di finance, memprediksi *return* (perubahan harga) jauh lebih stabil daripada memprediksi harga absolut.

3.2.2 Unsupervised Learning: Penemuan Pola

Di sini, kita tidak memiliki label target (Y). Algoritma dibiarkan mencari struktur tersembunyi dalam data.

- **Clustering:** Mengelompokkan saham yang bergerak serupa untuk diversifikasi portofolio. Atau, seperti topik utama buku ini: mengelompokkan hari-hari perdagangan ke dalam "Rezim Pasar" (misal: Cluster Volatilitas Tinggi vs Rendah).
- **Dimensionality Reduction (PCA):** Mengompres ribuan indikator teknikal menjadi beberapa "Faktor Risiko" utama untuk menghindari kutukan dimensi.

3.2.3 Reinforcement Learning: Optimalisasi Tindakan

Paradigma ini paling mirip dengan cara manusia belajar trading. Sebuah "Agen" berinteraksi dengan "Lingkungan" (Pasar) dan menerima "Reward" (Profit/Loss). Tujuannya bukan sekadar memprediksi harga, tetapi mengambil serangkaian keputusan (Beli/Jual/Tahan) yang memaksimalkan total kekayaan jangka panjang. RL sangat kuat untuk manajemen risiko dan eksekusi order yang optimal.

3.3 Tantangan Unik ML di Finance

Mengapa fisikawan pintar sering gagal menjadi trader sukses? Karena data keuangan berbeda.

3.3.1 Low Signal-to-Noise Ratio

Dalam pengenalan gambar, gambar kucing tetaplah kucing; sinyalnya jelas. Di pasar, sinyal pergerakan harga seringkali sangat lemah, tersembunyi di balik gunung *noise* (transaksi acak). Akurasi prediksi 51-54% sudah dianggap "Sangat Bagus" di trading frekuensi tinggi. Ini menuntut disiplin statistik yang ketat untuk tidak menipu diri sendiri.

3.3.2 Non-stationarity dan Concept Drift

Ini adalah musuh terbesar. Distribusi data berubah seiring waktu. Strategi yang dilatih pada tahun 2010 (pasar tenang pasca-krisis) mungkin gagal total di 2020 (krisis pandemi). Model ML di finance harus bersifat *adaptif* atau sering dilatih ulang (*retrained*) untuk tetap relevan. Apa yang kita pelajari hari ini mungkin kedaluwarsa besok.

3.3.3 Backtest Overfitting

”Menyiksa data sampai dia mengaku.” Sangat mudah untuk membuat strategi yang menghasilkan Sharpe Ratio 3.0 di data masa lalu (*in-sample*) dengan memilih parameter terbaik secara surut. Namun, strategi ini hampir pasti rugi di pasar nyata (*out-of-sample*). Teknik validasi khusus diperlukan untuk memitigasi ini.

3.4 Validasi Model yang Benar

3.4.1 Bahaya Acak (Random K-Fold)

Dalam ML standar, kita sering mengacak data sebelum membaginya menjadi K-Fold. Di data time series, ini fatal! Menggunakan data masa depan (esok) untuk memprediksi masa lalu (kemarin) adalah kecurangan (*look-ahead bias*).

3.4.2 Walk-Forward Analysis

Metode validasi emas untuk time series.

1. Latih model pada data Tahun 1-3. Uji di Tahun 4.
2. Geser jendela: Latih di Tahun 2-4. Uji di Tahun 5.
3. Dan seterusnya.

Ini mensimulasikan pengalaman trader yang sebenarnya yang harus beradaptasi dengan aliran data baru.

3.4.3 Purged K-Fold Cross Validation

Diusulkan oleh Marcos Lopez de Prado. Teknik ini menghapus data di perbatasan antara set Training dan Testing (purging) untuk mencegah kebocoran informasi dari korelasi serial (karena trade hari ini dipengaruhi trade kemarin).

Bagian II

Data dan Feature Engineering

Bab 4

Sumber Data Pasar

Bahan bakar utama algoritma ML adalah data. Kualitas output model (Garbage Out) sangat bergantung pada kualitas input data (Garbage In).

4.1 Price Data (Market Data)

4.1.1 OHLCV: Standar Industri

Format data yang paling umum adalah **Open, High, Low, Close, Volume (OHLCV)** yang di-sampel berdasarkan waktu (Time Bars).

- **Open:** Harga transaksi pertama pada periode tersebut.
- **High/Low:** Rentang ekstrem harga, penting untuk mengukur volatilitas.
- **Close:** Harga terakhir, sering dianggap sebagai harga "konsensus" final periode itu.
- **Volume:** Jumlah aset yang berpindah tangan, indikator validitas pergerakan harga.

Kelemahan Time Bars adalah mereka memotong aktivitas pasar secara artifisial. Satu jam di jam makan siang yang sepi diperlakukan sama dengan satu jam saat rilis berita Non-Farm Payroll, padahal nilai informasinya sangat berbeda.

4.1.2 Tick Data

Sumber data bervariasi dari yang gratis (Yahoo Finance) hingga premium (Bloomberg, Refinitiv). Kualitas data berbayar biasanya jauh lebih baik dalam hal penyesuaian aksi korporasi dan kelengkapan historis.

4.2 Fundamental Data

4.2.1 Economic Indicators

Data makroekonomi (NFP, GDP, CPI) yang dirilis secara berkala. Perubahan rezim sering dipicu oleh kejutan pada rilis data ini.

4.2.2 Earnings Reports

Laporan laba rugi kuartalan perusahaan. Kejutan pendapatan (*earnings surprise*) adalah penggerak harga utama untuk saham individu.

4.2.3 Balance Sheet Metrics

Rasio utang, arus kas, dan nilai buku. Penting untuk model investasi jangka panjang tipe *value investing*.

4.2.4 Macroeconomic Data

Suku bunga bank sentral dan kebijakan moneter adalah pendorong utama siklus makro pasar.

4.3 Alternative Data

4.3.1 Sentiment dari News dan Social Media

Analisis sentimen Twitter/X, Reddit (WallStreetBets), dan berita keuangan menggunakan NLP. "Fear" di media sosial sering mendahului penurunan harga.

4.3.2 Web Scraping

Mengumpulkan data harga produk dari situs e-commerce untuk memprediksi inflasi secara real-time, atau data lowongan kerja untuk memprediksi kesehatan ekonomi.

4.3.3 Satellite Imagery

Menghitung jumlah mobil di parkir retail untuk memprediksi pendapatan, atau memantau tangki minyak untuk mengestimasi cadangan global.

4.3.4 Credit Card Transaction

Data agregat pengeluaran konsumen memberikan pandangan hampir real-time tentang status ekonomi ritel.

4.3.5 Google Trends

Volume pencarian kata kunci tertentu (misal: "recesi", "beli emas", "cara jual saham") berkorelasi kuat dengan perilaku investor ritel.

4.4 Market Microstructure Data

4.4.1 Order Book Data (L2/L3)

Melihat kedalaman pasar (*Market Depth*). Ketidakseimbangan pesanan beli/jual di order book (*Order Imbalance*) adalah prediktor kuat pergerakan harga jangka pendek.

4.4.2 Trade Flow

Arah agresivitas perdagangan. Apakah pembeli memukul harga ask (agresif) atau penjual memukul harga bid?

4.4.3 Price Discovery

Proses bagaimana harga baru terbentuk melalui interaksi pembeli dan penjual.

4.4.4 High-Frequency Trading (HFT)

Algoritma ultra-cepat yang menyediakan likuiditas tetapi juga dapat memicu volatilitas kilat. Model kita perlu memperhitungkan noise yang dihasilkan HFT.

Bab 5

Data Preprocessing

5.1 Data Cleaning

5.1.1 Missing Data Handling

Dalam time series keuangan, menghapus baris (*drop*) dapat merusak struktur waktu. Metode umum adalah *Forward Fill* (menggunakan harga terakhir yang diketahui) atau interpolasi linier untuk gap pendek.

5.1.2 Outlier Detection

Flash crash atau kesalahan data feed dapat menciptakan *spikes* harga yang tidak realistis. Filter statistik seperti *Median Absolute Deviation* (MAD) lebih kuat daripada Standar Deviasi untuk mendeteksi ini.

5.1.3 Corporate Actions Adjustment

Harga saham harus disesuaikan (*adjusted*) untuk dividen dan pemecahan saham (*stock splits*) agar grafik sejarah konsisten. Tanpa ini, model akan melihat "gap" harga palsu sebagai sinyal trading.

5.1.4 Data Quality Checks

Memastikan tidak ada duplikasi cap waktu (*timestamps*), harga negatif, atau volume nol pada jam perdagangan aktif.

5.2 Normalization dan Transformation

5.2.1 Returns vs Prices

Harga aset mentah biasanya non-stasioner (memiliki tren). Model ML bekerja lebih baik pada data stasioner. Menggunakan *returns* (persentase perubahan) membuat data lebih stasioner.

5.2.2 Log Returns

Lebih disukai daripada *simple returns* karena sifat aditifnya (log return periode panjang adalah jumlah log return periode pendek) dan distribusi yang lebih simetris (mendekati normal), memudahkan pemodelan statistik.

5.2.3 Standardization

Banyak algoritma (seperti SVM dan Neural Networks) sensitif terhadap skala. *Z-score normalization* (mean=0, std=1) atau *Min-Max Scaling* memastikan semua fitur memiliki bobot awal yang setara.

5.2.4 Handling Non-stationarity

Selain differencing (returns), teknik seperti *Fractional Differentiation* (Lopez de Prado) dapat digunakan untuk membuat seri stasioner sambil mempertahankan memori jangka panjang sebanyak mungkin.

5.3 Resampling

Mengubah frekuensi data.

5.3.1 Time-based Resampling

Metode standar (bar 1 menit, 1 jam, 1 hari). Kelemahannya: pasar tidak aktif secara merata sepanjang waktu (misalnya, jam makan siang sepi).

5.3.2 Tick Bars

Sampling setiap N transaksi. Ini menyesuaikan dengan aktivitas pasar, tetapi ukuran transaksi bisa bervariasi.

5.3.3 Volume Bars

Sampling setiap N saham/kontrak yang diperdagangkan. Lebih baik dalam menangkap periode aktivitas tinggi.

5.3.4 Dollar Bars

Sampling setiap nilai transaksi dolar tertentu (misal: setiap \$1 juta yang diperdagangkan). Ini adalah metode paling stabil secara statistik karena menormalkan fluktuasi harga dan volume.

5.4 Train-Test Split untuk Time Series

5.4.1 Temporal Split

Data harus dipisah secara kronologis (Masa Lalu untuk Train, Masa Depan untuk Test). Pengocokan acak (*random shuffling*) dilarang keras karena merusak urutan waktu.

5.4.2 Purging dan Embargo

Konsep dari Marcos Lopez de Prado.

- **Purging:** Menghapus data di perbatasan antara Train dan Test set untuk mencegah kebocoran informasi dari label yang "tumpang tindih" (overlapping labels).
- **Embargo:** Menambahkan jarak waktu ekstra setelah set Test sebelum menggunakan data selanjutnya untuk Train (pada cross-validation) guna menghilangkan korelasi serial yang tersisa.

5.4.3 Cross-Validation Strategies

Menggunakan *Walk-Forward Validation* atau *Blocking Rolling Window* alih-alih K-Fold standar.

Bab 6

Technical Indicators sebagai Features

Indikator teknikal adalah bentuk paling dasar dari *Feature Engineering* dalam trading.

6.1 Trend Indicators

6.1.1 Moving Averages (SMA, EMA)

Meratakan data harga untuk melihat tren dasar. SMA (Simple) memberi bobot sama rata, EMA (Exponential) memberi bobot lebih pada data terbaru. Crossover (Golden Cross/Death Cross) adalah fitur biner sederhana.

6.1.2 MACD (Moving Average Convergence Divergence)

Indikator momentum mengikuti tren yang menunjukkan hubungan antara dua moving averages dari harga. Histogram MACD sering digunakan untuk mendeteksi perubahan momentum tren.

6.1.3 ADX (Average Directional Index)

Mengukur kekuatan tren tanpa mempedulikan arahnya. Nilai ADX tinggi menunjukkan pasar sedang trending kuat (cocok untuk strategi trend-following), ADX rendah menunjukkan pasar sideways (cocok untuk mean-reversion).

6.1.4 Parabolic SAR

Indikator untuk menentukan titik keluar (stop loss) potensial dan pembalikan arah.

6.2 Momentum Indicators

6.2.1 RSI (Relative Strength Index)

Osilator yang mengukur kecepatan dan perubahan pergerakan harga. Level ≥ 70 (Overbought) dan ≤ 30 (Oversold) adalah fitur input klasik untuk mendeteksi pembalikan mean.

6.2.2 Stochastic Oscillator

Membandingkan harga penutupan tertentu dengan rentang harganya selama periode waktu tertentu. Berguna untuk menentukan titik masuk di pasar sideways.

6.2.3 Rate of Change (ROC)

Persentase perubahan harga antara periode saat ini dan n periode lalu. Mengukur kecepatan tren secara murni.

6.2.4 Williams %R

Indikator momentum yang bergerak terbalik dibanding Stochastic, mengukur level overbought/oversold.

6.3 Volatility Indicators

6.3.1 Bollinger Bands

Pita volatilitas yang ditempatkan di atas dan di bawah moving average. Penyempitan pita (*Bollinger Squeeze*) sering mendahului ledakan volatilitas besar (perubahan rezim).

6.3.2 ATR (Average True Range)

Mengukur volatilitas pasar dengan menguraikan seluruh rentang harga aset untuk periode tersebut. Sering digunakan untuk menetapkan target stop-loss dinamis (volatility-based stop).

6.3.3 Standard Deviation

Ukuran statistik dispersi harga dari rata-ratanya.

6.3.4 Keltner Channels

Serupa dengan Bollinger Bands tetapi menggunakan ATR untuk menetapkan lebar pita, sehingga lebih responsif terhadap perubahan volatilitas nyata.

6.4 Volume Indicators

6.4.1 On-Balance Volume (OBV)

Menggunakan aliran volume untuk memprediksi perubahan harga saham. Ide dasarnya: volume mendahului harga. Divergensi antara OBV dan harga adalah sinyal kuat.

6.4.2 Volume Price Trend

Menggabungkan harga dan volume.

6.4.3 Accumulation/Distribution

Mencoba mengukur aliran uang masuk dan keluar dari suatu sekuritas.

6.4.4 Money Flow Index

RSI yang ditimbang dengan volume.

6.5 Custom Indicators

6.5.1 Kombinasi Indicators

Membuat "super-indikator" dengan menggabungkan sinyal dari trend dan momentum (misal: "RSI di atas 50 DAN Harga di atas EMA200").

6.5.2 Adaptive Indicators

Indikator yang parameternya menyesuaikan diri secara otomatis dengan siklus dominan pasar saat ini (misal: *Adaptive Moving Average* karya Perry Kaufman).

6.5.3 Multi-timeframe Features

Memasukkan fitur dari kerangka waktu yang lebih tinggi (misal: tren Mingguan) sebagai konteks untuk model yang memprediksi pergerakan Harian.

Bab 7

Advanced Feature Engineering

Jika indikator teknikal adalah "kulit" pasar, maka fitur statistik dan mikrostruktur adalah "organ dalam"nya. Di bab ini, kita akan menggali fitur-fitur canggih yang jarang digunakan oleh trader ritel tetapi menjadi makanan sehari-hari algoritma institusi.

7.1 Statistical Features

Fitur statistik menangkap properti distribusi data yang tidak terlihat oleh mata telanjang pada grafik harga.

7.1.1 Rolling Statistics (Mean, Variance)

Pasar yang efisien seharusnya memiliki return dengan mean nol. Pergeseran mean (*drift*) yang signifikan dalam jendela waktu rolling (misal 20 hari) adalah sinyal tren. Lebih penting lagi adalah *Rolling Variance*. Lonjakan varians seringkali terjadi *sebelum* harga jatuh tertembus. Kita menggunakan jendela waktu eksponensial (EWM) untuk memberi bobot lebih pada data terbaru.

7.1.2 Higher Moments (Skewness Kurtosis)

Dua momen pertama (Mean, Varians) mengasumsikan distribusi Normal. Pasar tidak Normal.

- **Skewness (Kemencengan):** Mengukur asimetri distribusi return. Skewness negatif yang besar (ekor kiri panjang) menandakan risiko *crash* yang tinggi ("Naga Hitam").
- **Kurtosis (Keruncingan):** Mengukur ketebalan ekor (*fat tails*). Kurtosis > 3 (Leptokurtic) berarti probabilitas kejadian ekstrem (sangat untung atau sangat rugi) jauh lebih tinggi daripada prediksi model Gaussian.

7.1.3 Autocorrelation dan Serial Correlation

Mengukur seberapa kuat harga hari ini dipengaruhi oleh harga kemarin.

$$\rho_k = \frac{\sum_{t=k+1}^T (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^T (y_t - \bar{y})^2}$$

Pasar yang efisien memiliki autokorelasi mendekati nol (Random Walk). Lonjakan autokorelasi positif menandakan tren (momentum), sedangkan negatif menandakan mean-reversion.

7.1.4 Fractal Dimension (Hurst Exponent)

Mengukur "kekasaran" grafik harga untuk menentukan sifat memori jangka panjang (Long-term Memory). Nilai Hurst Exponent (H):

- $0.5 < H < 1.0$: Trending (Persistent). Sinyal untuk strategi Trend Following.
- $0.0 < H < 0.5$: Mean Reverting (Anti-persistent). Sinyal untuk strategi Reversion.
- $H = 0.5$: Random Walk.

7.2 Microstructure Features

Mengintip ke dalam mesin pencocokan order (matching engine).

7.2.1 Bid-Ask Spread dynamics

Spread bukan biaya statis. Spread yang melebar secara tiba-tiba adalah proksi ketakutan *market maker*. Saat market maker mendeteksi adanya "Informed Trader", mereka melebarkan spread untuk melindungi diri. Ini sinyal volatilitas.

7.2.2 Order Imbalance

Rasio volume beli agresif vs volume jual agresif.

$$\rho = \frac{V_{buy} - V_{sell}}{V_{buy} + V_{sell}}$$

Jika order beli mendominasi ($\rho > 0$) tetapi harga tidak naik, ini tanda *absorption* (distribusi tersembunyi).

7.2.3 Kyle's Lambda (Amihud Illiquidity)

Mengukur *market impact cost*: seberapa besar harga bergerak untuk setiap unit volume yang diperdagangkan ($\Delta P / \Delta V$). Lonjakan Lambda adalah tanda bahaya kerapuhan pasar (*fragility*).

7.3 Feature Selection Techniques

7.3.1 Correlation Clustering

Mengelompokkan fitur statistik yang redundan dengan Hierarchical Clustering, lalu mengambil satu perwakilan dari setiap cluster.

7.3.2 Feature Importance (MDI)

Menggunakan Random Forest untuk mengukur *Mean Decrease Impurity*. Fitur yang paling banyak mengurangi entropi adalah fitur terbaik.

Bagian III

Metodologi dan Algoritma

Bab 8

Regime Labeling

Langkah paling kritis dalam supervised learning bukanlah modelnya, tapi labelnya ("Ground Truth").

8.1 Metode Labeling Manual vs Data-Driven

8.1.1 Price-based Rules (Naive)

"Jika harga di atas SMA200, label = Bull". Terlalu sederhana dan lagging.

8.1.2 Drawdown-based Labeling

Mendefinisikan rezim berdasarkan "rasa sakit" (Drawdown). Berguna untuk analisis risiko historis.

8.2 Statistical Change Point Detection

Mencari titik di mana properti statistik data berubah secara tiba-tiba menggunakan uji statistik (seperti CUSUM atau Chow Test).

8.3 Hidden Markov Models (HMM)

Metode emas (*de facto standard*) untuk pemodelan rezim tanpa pengawasan (*unsupervised*).

8.3.1 Konsep Latent States

HMM berasumsi bahwa pasar digerakkan oleh "mesin keadaan" (*state machine*) yang tidak terlihat. Kita hanya bisa melihat Observasi (O_t : return, volatilitas), tapi tidak bisa melihat State (S_t : Bull, Bear).

8.3.2 Matriks Transisi

Probabilitas perpindahan antar state. Sifat "lengket" (*sticky*) dari regim pasar dimodelkan di sini (peluang tetap di state yang sama tinggi).

8.3.3 Gaussian Mixture Emissions

Setiap state memancarkan data berdasarkan distribusi probabilitas yang unik.

- **Bull:** Mean Positif, Varians Rendah.
- **Bear:** Mean Negatif, Varians Tinggi.

8.4 Regime-Switching Models Lainnya

Selain HMM, kita bisa menggunakan Threshold Auto-Regressive (TAR) atau Markov Switching Auto-Regressive (MSAR).

Bab 9

Classification Models untuk Regime Prediction

Once we have our labels (from HMM or Manual), we can train supervised classifiers to predict them out-of-sample.

9.1 Traditional Machine Learning

9.1.1 Logistic Regression

Model dasar yang memberikan probabilitas linear.

9.1.2 Random Forest

Ensemble dari Decision Trees. Tahan terhadap overfitting dan outlier. Bisa menangani hubungan non-linear antar fitur.

9.1.3 Gradient Boosting (XGBoost, LightGBM)

Model paling populer di kompetisi Kaggle. Sangat akurat tetapi perlu tuning hyperparameter yang hati-hati.

9.1.4 Support Vector Machines (SVM)

Mencari hyperplane pemisah optimal. Bagus untuk dataset kecil dengan dimensi tinggi.

9.2 Handling Imbalanced Data

Data "Crash" sangat jarang.

- **SMOTE**: Oversampling kelas minoritas secara sintetis.
- **Class Weights**: Memberi penalti lebih besar jika salah menebak kelas minoritas.

Bab 10

Deep Learning untuk Regime Detection

10.1 Feedforward Neural Networks (MLP)

Jaringan saraf standar. Cocok untuk data tabular. Membutuhkan normalisasi input (Z-score) dan teknik regularisasi (Dropout).

10.2 Convolutional Neural Networks (CNN)

Biasanya untuk gambar, tapi efektif untuk time series 1D. Filter konvolusi bisa belajar mengenali pola lokal seperti "Head and Shoulders" atau lonjakan volatilitas pendek.

10.3 Recurrent Neural Networks (RNN)

10.3.1 LSTM (Long Short-Term Memory)

Dirancang untuk mengingat dependensi jangka panjang. LSTM memiliki "memory cell" yang bisa menyimpan informasi tren dari masa lalu.

10.3.2 Attention Mechanisms dan Transformers

Self-Attention memungkinkan model untuk "fokus" pada titik-titik waktu tertentu di masa lalu yang paling relevan. Arsitektur *Transformer* (seperti yang digunakan di LLM) kini mulai mendominasi time-series forecasting (misal: Temporal Fusion Transformer).

Bab 11

Time Series Models

11.1 Classical Time Series

11.1.1 ARIMA

Model parametrik klasik. Bagus untuk data stasioner tetapi gagal menangkap perubahan rezim yang tiba-tiba.

11.1.2 GARCH untuk Volatility

Standar industri untuk memprediksi volatilitas. GARCH memodelkan *volatility clustering*.

11.1.3 VAR (Vector Autoregression)

Perluasan multivariate dari ARIMA. Melihat hubungan timbal balik antar beberapa aset.

11.2 Modern Time Series ML

11.2.1 Prophet

Library dari Facebook. Kuat menangani musiman dan liburan.

11.2.2 N-BEATS

Arsitektur Deep Learning murni untuk forecasting yang mengalahkan model statistika.

Bab 12

Unsupervised Learning untuk Regime Discovery

12.1 Clustering Methods

12.1.1 K-Means

Mempartisi data menjadi K kelompok berdasarkan kemiripan fitur (volatilitas, return).

12.1.2 GMM (Gaussian Mixture Models)

Versi probabilistik dari K-Means. Lebih fleksibel karena mengakomodasi varians yang berbeda tiap cluster.

12.2 Dimensionality Reduction

12.2.1 PCA

Komponen utama pertama seringkali merepresentasikan Beta Pasar.

12.2.2 Autoencoders

Jaringan saraf untuk kompresi data. *Reconstruction Error* dari Autoencoder bisa digunakan sebagai sinyal anomali pasar (Crash Detector).

Bab 13

Reinforcement Learning

13.1 Konsep RL untuk Trading

RL adalah tentang belajar mengambil tindakan (*Action*) untuk memaksimalkan keuntungan jangka panjang (*Reward*).

13.2 RL Algorithms

13.2.1 Deep Q-Networks (DQN)

Menggunakan Neural Network untuk memperkirakan nilai setiap tindakan.

13.2.2 PPO (Proximal Policy Optimization)

Algoritma policy-gradient yang stabil dan menjadi standar industri saat ini untuk trading bot.

13.3 RL untuk Regime-aware Trading

Memasukkan "Label Rezim" (dari HMM) ke dalam state space agen RL, memberinya konteks makro untuk mengambil keputusan yang lebih bijak (misal: lebih konservatif saat Rezim Bear).

Bagian IV

Evaluasi dan Optimisasi

Bab 14

Evaluasi Model

14.1 Classification Metrics

14.1.1 Precision, Recall, F1

Akurasi menyesatkan di finance. Recall (kemampuan mendeteksi Crash) seringkali lebih penting daripada Precision.

14.1.2 Confusion Matrix

Menganalisis tipe kesalahan: False Positive (Alarm Palsu) vs False Negative (Gagal Deteksi Bahaya).

14.2 Financial Metrics

14.2.1 Sharpe Ratio Sortino Ratio

Mengukur return per unit risiko.

14.2.2 Maximum Drawdown

Resiko kerugian terbesar dari puncak ke lembah.

14.3 Backtesting yang Benar

14.3.1 Walk-Forward Validation

Melatih pada masa lalu, menguji pada masa depan, lalu menggeser jendela waktu.

14.3.2 Purged Cross-Validation

Menghapus data buffer di perbatasan train/test untuk mencegah kebocoran informasi.

Bab 15

Model Optimization

15.1 Hyperparameter Tuning

15.1.1 Grid Search vs Random Search

Random search seringkali lebih efisien.

15.1.2 Bayesian Optimization (Optuna)

Menggunakan probabilitas untuk menebak kombinasi parameter terbaik berikutnya, secara drastis mengurangi waktu pencarian.

15.2 Feature Selection

15.2.1 Recursive Feature Elimination (RFE)

Secara iteratif membuang fitur terlemah.

15.2.2 SHAP Values

Menggunakan Game Theory untuk menjelaskan kontribusi setiap fitur terhadap prediksi model (Explainable AI).

Bab 16

Model Interpretability

16.1 Explainable AI (XAI)

Regulasi menuntut penjelasan. Mengapa model menjual?

16.1.1 SHAP LIME

Visualisasi kontribusi fitur lokal dan global.

16.1.2 Feature Importance Plot

Penting untuk sanity check: Apakah fitur yang dipakai model masuk akal secara ekonomi?

Bab 17

Implementasi Sistem Real-time

17.1 Arsitektur Sistem

17.1.1 Data Pipeline

Sistem harus memiliki ETL (*Extract, Transform, Load*) otomatis yang mengambil data baru, membersihkannya, dan menghitung fitur sama persis seperti saat fase training (*pre-processing consistency*).

17.1.2 Model Serving

Cara model diakses. Bisa berupa *REST API* (Flask/FastAPI) yang menerima JSON data pasar dan mengembalikan prediksi, atau sistem *embedded* di dalam platform trading.

17.1.3 API Design

Desain endpoint yang efisien (misal: `/predictregime`, `/getmetrics`). *Keamanan*(*APIKey*, *ratelimiting*).

17.1.4 Scalability

Sistem harus mampu menangani lonjakan beban data saat volatilitas pasar tinggi tanpa *latency* yang meningkat.

17.2 Real-time Data Processing

17.2.1 Streaming Data

Menggunakan Kafka atau RabbitMQ untuk menangani aliran data tick-by-tick secara asinkron.

17.2.2 Low-latency Processing

Optimisasi kode Python (misal: menggunakan Cython atau Numba) atau menulis ulang bagian kritis dalam C++/Rust/Go untuk eksekusi order milidetik.

17.2.3 Data Quality Monitoring

Peringatan otomatis jika data feed mati atau memberikan nilai yang tidak masuk akal (misal: harga saham tiba-tiba nol).

17.3 Model Deployment

17.3.1 Model Serialization

Menyimpan model terlatih sebagai file (Pickle, Joblib, ONNX) agar bisa dimuat ulang di server produksi tanpa retraining.

17.3.2 Version Control

Mencatat versi model (misal: v1.0, v1.1) dan data yang digunakan untuk melatihnya (MLflow, DVC). Ini penting untuk audit jika performa tiba-tiba anjlok.

17.3.3 A/B Testing

Menjalankan model baru (Challenger) diam-diam di samping model lama (Champion) dengan uang kertas (*paper trading*) sebelum menggantinya secara live.

17.3.4 Model Monitoring

Dashboard (Grafana) untuk memantau "kesehatan" model: apakah distribusi prediksi berubah? Apakah akurasi harian menurun drastis?

17.4 Infrastructure

17.4.1 Cloud vs On-premise

AWS/GCP menawarkan fleksibilitas dan layanan ML terkelola (*SageMaker*), tapi server on-premise (colocation) lebih cepat (low latency) dan lebih aman untuk strategi HFT.

17.4.2 Containerization (Docker)

Membungkus kode dan semua dependensi dalam kontainer agar berjalan sama persis di laptop developer dan server produksi.

17.4.3 Orchestration (Kubernetes)

Mengelola ratusan kontainer secara otomatis, memastikan sistem selalu hidup (*high availability*).

Bab 18

Trading Strategies berbasis Regime

18.1 Regime-conditional Strategies

Ide inti: Ubah "mode" trading berdasarkan prediksi rezim.

18.1.1 Bull Market Strategies

Fokus: **Long-only, Momentum, Leverage.**

- Beli saat breakout atau pullback (Buy the Dip).
- Gunakan leverage moderat karena tren naik cenderung stabil.
- Pegang posisi lebih lama (*Let profits run*).

18.1.2 Bear Market Strategies

Fokus: **Cash Conservation, Short Selling, Volatility.**

- Keluar dari pasar (100% Cash) adalah posisi yang valid.
- Short-selling indeks atau saham lemah.
- Beli volatilitas (Long VIX).
- Strategi Mean-Reversion sangat agresif (jual saat rally).

18.1.3 Sideways Market Strategies

Fokus: **Income Generation, Mean Reversion.**

- Jual opsi (Covered Call, Iron Condor) untuk mendapatkan premium dari time decay (*Theta*).
- Beli di Support bawah, Jual di Resistance atas (*Range Trading*).

18.2 Portfolio Allocation

18.2.1 Dynamic Asset Allocation

Menggeser bobot portfolio dari Saham (Equity) ke Obligasi/Emas saat probabilitas rezim resesi $\geq 50\%$.

18.2.2 Risk Parity

Mengalokasikan aset berdasarkan kontribusi risiko, bukan nilai dolar. Di rezim volatilitas tinggi, posisi saham dikurangi secara otomatis untuk menjaga target volatilitas portfolio konstan.

18.2.3 Tactical Allocation

Perubahan jangka pendek untuk memanfaatkan inefisiensi sesaat (misal: rotasi sektor dari Tech ke Energy saat sinyal inflasi menyala).

18.3 Risk Management

18.3.1 Position Sizing

Rumus Kelly Criterion yang disesuaikan dengan keyakinan rezim. Pertaruhkan lebih sedikit saat sinyal rezim tidak pasti.

18.3.2 Stop Loss Strategies

Stop loss longgar di Bull Market (biarkan bernafas), Stop loss sangat ketat di Bear Market.

18.3.3 Hedging

Membeli asuransi portofolio (Options Put) hanya saat sinyal "Bahaya" menyala, sehingga menghemat biaya premi asuransi saat pasar aman.

18.3.4 Diversification

Di saat krisis, korelasi aset mendekati 1. Diversifikasi tradisional gagal. Strategi rezim mencari aset "Crisis Alpha" (seperti Managed Futures) yang justru naik saat saham jatuh.

18.4 Execution

18.4.1 Order Types

Market order untuk masuk cepat saat breakout rezim penting. Limit order untuk mengambil profit di target.

18.4.2 Execution Algorithms

VWAP/TWAP algo untuk memecah order besar agar tidak menggerakkan pasar.

18.4.3 Market vs Limit Orders

Kapan harus agresif (memakan likuiditas) dan kapan harus pasif (menyediakan likuiditas dan dapat rebate).

Bab 19

Studi Kasus: Saham

19.1 Data Preparation

Menggunakan data harian S&P 500 (SPY) dari tahun 2000-2023. Fitur mencakup technical indicators (RSI, MACD) dan data makro (Yield Curve 10Y-2Y, VIX). Data dibagi menjadi Train (2000-2015), Validation (2016-2019), dan Test (2020-2023).

19.2 Feature Engineering

Membuat fitur "Jarak dari All-Time High" dan "Sektor Rotasi Alpha" (XLK vs XLE). Label rezim dibuat menggunakan algoritma HMM 2-state pada volatilitas mingguan.

19.3 Model Development

Melatih Random Forest Classifier dengan `'class_weight = 'balanced'`. *Hyperparameter 'max_depth' dibatasi*

19.4 Backtesting Results

Strategi "Long saat Bull, Cash saat Bear" menghasilkan CAGR 12% vs 8% Buy-and-Hold, dengan Max Drawdown hanya -15% (vs -34

19.5 Live Trading Performance

Paper trading selama 6 bulan menunjukkan slippage 0.05% per trade. Model berhasil keluar sebelum koreksi pasar Agustus 2023.

19.6 Lessons Learned

Rezim "Sideways" seringkali salah diklasifikasikan sebagai awal Bull, menyebabkan "whipsaw" (beli lalu segera rugi). Penambahan filter ADX membantu mengurangi signal palsu ini.

Bab 20

Studi Kasus: Cryptocurrency

20.1 Karakteristik Crypto Markets

Pasar 24/7 tanpa henti, volatilitas ekstrim (sering $\pm 5\%$ sehari), dan dominasi emosi ritel. Data on-chain (aktivitas dompet paus) adalah sumber alpha unik.

20.2 Data Sources

Data OHLCV 1-jam dari Binance untuk BTCUSDT dan ETHUSDT. Data sentimen dari "Fear and Greed Index" Crypto. Data on-chain dari Glassnode (Net Unrealized Profit/Loss).

20.3 Model Adaptation

Menggunakan LSTM (Deep Learning) karena pola sekuensial "pump and dump" sangat kuat. Window input diperpendek menjadi 60 jam (vs 60 hari di saham) karena dinamika pasar yang lebih cepat.

20.4 Results dan Analysis

Model 3-state (Bull, Bear, Crash). Strategi berhasil menghindari crash FTX (Nov 2022) dengan beralih ke stablecoin 2 hari sebelumnya karena mendeteksi lonjakan volatilitas aneh dan aliran keluar dana besar-besaran. Namun, model sering terlambat masuk kembali saat "V-shape recovery".

Bab 21

Studi Kasus: Forex

21.1 Currency Pair Selection

Fokus pada pasangan mata uang utama (EURUSD, USDJPY, GBPUSD) yang memiliki likuiditas tertinggi dan spread terendah.

21.2 Multi-timeframe Analysis

Model menggunakan input dari grafik H4 (4 jam) untuk sinyal taktis, dan grafik D1 (Harian) untuk bias strategis.

21.3 Macro Factors

Memasukkan selisih suku bunga (Interest Rate Differential) antara Fed dan ECB sebagai fitur utama.

21.4 Implementation

Strategi "Mean Reversion" aktif saat sesi Asia (sideways), dan strategi "Momentum Breakout" aktif saat sesi London/New York overlap. Model ML bertindak sebagai "dosen" yang memilih strategi mana yang dipakai jam ini.

Bab 22

Studi Kasus: Multi-asset

22.1 Cross-asset Correlations

Menganalisis matriks korelasi bergulir antara Saham, Obligasi, Emas, dan Bitcoin.

22.2 Global Regime Detection

Membangun "Global Risk Indicator". Jika semua aset berkorelasi positif dan jatuh bersamaan, ini adalah rezim "Liquidity Crisis" (seperti Maret 2020).

22.3 Portfolio Construction

Menggunakan "Hierarchical Risk Parity" (HRP) yang ditenagai oleh prediksi rezim untuk mengalokasikan bobot aset.

22.4 Performance Evaluation

Portfolio multi-aset ini memberikan kurva ekuitas paling mulus, dengan volatilitas tahunan di bawah 8% meskipun return setara saham murni.

Bagian V

Topics Lanjutan

Bab 23

Online Learning dan Adaptive Models

23.1 Concept Drift

23.1.1 Deteksi Drift

Pasar berevolusi. Model yang dilatih pada data 2010 mungkin gagal total di 2024. Kita menggunakan uji statistik (seperti Kolmogorov-Smirnov test) untuk mendeteksi apakah distribusi data masuk baru berbeda signifikan dari data latih.

23.1.2 Adaptation Strategies

Jika drift terdeteksi, kita punya dua pilihan: Melatih ulang model (*retraining*) atau memberikan bobot lebih pada data terbaru (*instance weighting*).

23.2 Online Learning Algorithms

23.2.1 Incremental Learning

Algoritma yang bisa belajar satu per satu data baru tanpa melupakan ilmu lama sebelumnya, dan tanpa perlu melatih ulang dari nol (misalnya: Online Random Forest).

23.2.2 Transfer Learning

Melatih model dasar pada data pasar AS yang melimpah, lalu "mentransfer" pengetahuan itu untuk memprediksi pasar berkembang (seperti Indonesia) yang datanya sedikit.

23.2.3 Meta-learning

Belajar untuk beradaptasi dengan cepat. Model dilatih pada berbagai tugas (saham, crypto, forex) sehingga ketika menghadapi aset baru, ia bisa belajar hanya dengan sedikit contoh (*few-shot learning*).

23.3 Model Updating

23.3.1 Retraining Frequency

Seberapa sering kita melatih ulang? Setiap malam? Setiap minggu? Trade-off antara biaya komputasi dan kesegaran model.

23.3.2 Sliding Window

Menggunakan jendela data geser (misal: 1000 hari terakhir). Data yang lebih tua dari itu dibuang karena dianggap "basi".

23.3.3 Weighted Recent Data

Memberikan bobot eksponensial pada sampel data. Data kemarin jauh lebih penting daripada data 5 tahun lalu.

Bab 24

Alternative Approaches

24.1 Bayesian Methods

24.1.1 Bayesian Networks

Grafik asiklik berarah yang merepresentasikan hubungan probabilitas bersyarat. "Jika Minyak naik, maka inflasi naik (80%), maka Suku Bunga naik (70%), maka Saham turun."

24.1.2 Gaussian Processes

Metode non-parametrik yang, alih-alih memberikan satu garis prediksi, memberikan "awan probabilitas". Sangat bagus untuk mengukur ketidakpastian.

24.1.3 Bayesian Optimization

Efisien untuk mencari parameter strategi trading (misal: panjang MA) dengan jumlah percobaan minimal.

24.2 Fuzzy Logic

24.2.1 Fuzzy Sets

Pasar tidak hitam putih. Daripada "Bull" atau "Bear", logika fuzzy memungkinkan "Agak Bullish" atau "Sangat Bearish".

24.2.2 Fuzzy Rules

"JIKA harga naik CEPAT DAN volume TINGGI, MAKA BELI KUAT". Aturan linguistik ini lebih mudah dipahami manusia daripada bobot Neural Net.

24.2.3 Fuzzy Inference Systems

Sistem pengambilan keputusan berbasis aturan-aturan fuzzy.

24.3 Genetic Algorithms

24.3.1 Evolution Strategies

Membiakkan ribuan strategi trading acak. Yang rugi ”dibunuh”, yang untung ”dikawinkan” (crossover parameternya) untuk menghasilkan generasi anak yang lebih baik.

24.3.2 Strategy Optimization

Menemukan kombinasi parameter indikator yang optimal tanpa terjebak di optimum lokal.

24.4 Graph Neural Networks (GNN)

24.4.1 Market Networks

Memodelkan pasar sebagai grafik raksasa di mana simpul adalah Saham dan sisi adalah korelasi. GNN bisa memprediksi harga saham A berdasarkan pergerakan tetangganya di grafik.

24.4.2 Correlation Graphs

Struktur grafik bisa berubah dinamis setiap hari, menggambarkan dinamika penularan risiko sistemik.

Bab 25

Explainability dan Transparency

25.1 Black Box vs White Box Models

Regulator keuangan membenci Black Box. Kita harus bisa menjawab: "Mengapa algoritma menolak kredit nasabah ini?" atau "Mengapa bot menjual semua saham hari ini?"

25.2 Regulatory Requirements

GDPR di Eropa menuntut "Right to Explanation". Model deep learning murni seringkali gagal memenuhi standar ini.

25.3 Stakeholder Communication

Manajer investasi harus bisa menjelaskan logika model kepada investor. "Algoritma bilang begitu" bukan jawaban yang bisa diterima saat rugi.

25.4 Trust dan Validation

Kepercayaan dibangun melalui ribuan trade yang konsisten dan penjelasan yang masuk akal atas setiap keputusan.

Bab 26

Trends dan Inovasi

26.1 Quantum Machine Learning

Komputer kuantum menjanjikan percepatan eksponensial dalam optimisasi portofolio dan simulasi Monte Carlo.

26.2 Federated Learning

Bank-bank bisa melatih model deteksi penipuan bersama-sama tanpa perlu saling berbagi data nasabah sensitif. Privasi terjaga, tapi model jadi lebih pintar.

26.3 Neuromorphic Computing

Chip komputer yang meniru struktur otak manusia, memungkinkan AI berjalan dengan daya sangat rendah di perangkat edge (misal: satelit).

26.4 Alternative Data Explosion

Data semakin aneh: memantau bayangan tangki minyak dari luar angkasa, melacak kapal kargo via AIS, hingga menganalisis nada suara CEO saat earnings call.

Bab 27

Challenges dan Limitations

27.1 Market Regime Changes

Tantangan abadi. Segera setelah kita menemukan pola untung, pasar beradaptasi dan pola itu hilang (*Alpha Decay*).

27.2 Black Swan Events

ML dilatih pada data historis. Ia tidak bisa memprediksi kejadian yang belum pernah terjadi sebelumnya (seperti Pandemi COVID-19 pertama kali).

27.3 Data Quality Issues

”Garbage In, Garbage Out”. Sebagai apapun algoritmanya, jika data tick-nya bolong-bolong, hasilnya sampah.

27.4 Computational Limits

Melatih Transformer raksasa membutuhkan biaya listrik dan GPU yang masif, seringkali di luar jangkauan trader ritel.

27.5 Ethical Considerations

Apakah etis menggunakan algoritma untuk memprediksi kebangkrutan negara dan mengambil untung darinya? Atau menggunakan HFT untuk, secara teknis, ”mencuri” sen dari investor lambat (front-running)?

Bab 28

Kesimpulan

28.1 Rangkuman

Perjalanan kita dari teori pasar efisien, menembus kekacauan data tick, hingga arsitektur Deep Learning canggih.

28.2 Best Practices

Validasi yang ketat (*Purged Cross-Validation*), manajemen risiko paranoik, dan kerendahan hati bahwa pasar selalu benar.

28.3 Practical Recommendations

Mulailah dari yang sederhana (Logistic Regression). Fokus 80% waktu pada data, bukan model. Jangan pernah percaya hasil backtest 100%.

28.4 Final Thoughts

Machine Learning di finance bukan tentang menggantikan manusia, tapi memperkuat intuisi manusia dengan kemampuan komputasi statistik skala besar. Trader masa depan adalah Centaur: setengah manusia, setengah AI.

Lampiran A

Kode dan Implementasi

A.1 Setup Environment

A.1.1 Python Libraries

Pandas, NumPy, Scikit-learn, PyTorch, TensorFlow, TA-Lib, Zipline/Backtrader.

A.1.2 R Packages

quantmod, PerformanceAnalytics, TTR.

A.1.3 Trading Platforms

MetaTrader 5 (MQL5), Interactive Brokers API, CCXT (untuk Crypto).

A.2 Data Acquisition

A.2.1 API Examples

Kode contoh menarik data dari Yahoo Finance ('yfinance') dan Binance API.

A.2.2 Web Scraping Code

Skrip BeautifulSoup sederhana untuk mengambil data sentimen, data alternatif.

A.2.3 Database Setup

Menyimpan data time series di PostgreSQL dengan TimescaleDB atau InfluxDB.

A.3 Model Templates

A.3.1 Classification Template

Scikit-learn pipeline standar (Scaler -> PCA -> Random Forest).

A.3.2 Deep Learning Template

Kelas PyTorch Lightning untuk LSTM.

A.3.3 Backtesting Template

Kerangka kerja ‘Backtrader’ untuk menjalankan strategi regime-switching.

A.4 Complete Examples

A.4.1 End-to-end Pipeline

Notebook Jupyter lengkap dari download data sampai evaluasi Sharpe Ratio.

A.4.2 Production-ready Code

Struktur folder proyek Python yang bersih dengan logging dan error handling.

Lampiran B

Glossary

B.1 Machine Learning Terms

Bias, Variance, Overfitting, Epoch, Gradient Descent, Hyperparameter.

B.2 Finance Terms

Alpha, Beta, Delta, Gamma, Theta, Sharpe Ratio, Drawdown, Slippage.

B.3 Statistical Terms

Stationarity, Autocorrelation, Heteroskedasticity, Kurtosis, Skewness.

Daftar Pustaka

- [1] Lopez de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.
- Aronson, D. R. (2007). *Evidence-Based Technical Analysis*. Wiley.
- Jansen, S. (2020). *Machine Learning for Algorithmic Trading*. Packt.

Indeks

Terakhir diperbarui: 4 Februari 2026, 16:33 WIB